

Programação Inteira

Matheus Souza D'Andrea Alves

2018.2

Sumário

Introdução	3
Infos gerais	3
Fluxo máximo	3
Para solução	3
Modelagem	4
Categorização em formulação matemática	4
Composição de um problema	4
Definições	5
Modelando com variáveis inteiras.	5
Impor que uma ação x só pode ser feita se outra ação y for realizada.	5
Impor que uma variável X assumir apenas um dos valores de um conjunto finito $A = a_1, a_2, \dots, a_m$	6
Modelar funções lineares por partes	6
Modelando restrições disjuntas	7
Exemplo do emparelhamento perfeito	8
Exemplo da coloração de vértices	9
Fortalecer modelo enfraquecendo variáveis	9
Outra modelagem para coloração	11
Caxeiro viajante	11
Otimização relaxamento limites	12
<i>Branch and bound</i>	12
Plano de corte	12
<i>Branch and cut</i>	12
Relaxação Lagrangiana	12
Geração de colunas em PI	12

<i>Branch and Price</i>	12
Teoria Polédrica	12
Cortes	12
Faces	12
Facetas	12

Introdução

Infos gerais

Site

Salas:

- 2ª 306
- 4ª 202

Para a parte prática vamos implementar modelos e soluções usando o CPLEX ##
Programação linear

É um problema de otimização onde tanto a função objetivo quanto as restrições são lineares.

$\min/\max c^t X$

$Ax = b$

Modelagem

- Defina as variáveis do problema \rightarrow como representar uma solução do problema
- Definir as restrições do problema \rightarrow limites que definem o conjunto de pontos viáveis.
- A função objetivo \rightarrow que vai ponderar cada solução

Fluxo máximo

Existe um grafo direcionado $G = (V, E)$ com um e apenas um vértice fonte e sumidouro, $\forall (i, j) \in E(G)$ tem uma capacidade $C_{i,j}$. Queremos maximizar a quantidade de produto que passa de $F \rightarrow S$

São minhas variáveis: $X_{i,j} \rightarrow \forall (i, j) \in E(G)$. Representando a quantidade de produto que sai de i e chega em j .

São minhas restrições: $X_{i,j} \leq C_{i,j}$;

É meu objetivo: $\max \left\{ \sum_{j \in N^+(S)} X_{j,s} \right\}$

Para solução

Métodos:

- Simplex (exponencial, rápido)
- Ponto Interiores (polinomial, rápido)

Modelagem

Categorização em formulação matemática

As categorias quando modelamos problemas em matemática caem nas seguintes categorias.

- Linear ou não linear
- Convexo ou não-convexo
- Contínuo ou Discreto
- Estocástica ou Determinismo

Dentro dessa categorização a programação inteira busca resolver os problemas:

- Discretos
- Determinísticos
- Não convexos
- Lineares e não lineares

Isso faz com que seja possível resolver a maioria dos problemas combinatórios propostos em computação.

Composição de um problema

Um problema de programação matemática é composto de :

- Variáveis de decisão
- Restrições
- Função objetivo
- Parametro de entrada

Um problema de programação inteira tem formato:

$$\begin{cases} \min/\max\{f(x)\} \\ g_i(x) \begin{cases} \leq \\ = \\ \geq \end{cases} b_i \\ x \in X | X \text{ é discreto} \end{cases}$$

Definição:

Solução viável: valores atribuidos as variáveis que respeitam as Restrições.

Solução ótima: é uma solução viável que maximiza/minimiza a função objetivo.

Forma padrão:

$$\begin{cases} \max C^T x \\ A_x \leq b \\ x \in Z_+^p * R_+^{n-p} \end{cases}$$

A melhor formulação possível, é uma formulação que defina a involtória convexa dos pontos inteiros, i.e. as o poliedro minimal que contém toda solução inteira, se isso acontecer conseguimos resolver através de PL, e logo resolver de forma polinomial.

Porém, a involtória convexa não é conhecida, ou sua representação é exponencial.

Definições

Considere duas formulações A e B para o mesmo PPI. Denominamos P_A e P_B seus poliedros equivalentes.

A formulação A é dita *tão forte quanto* a formulação B se $P_A \subseteq P_B$. Se a inclusão é estrita, isto é, $P_A \subset P_B$ então dizemos que A é uma formulação mais forte.

Se F é o conjunto de todas as viáveis soluções desse PPI, então temos que $Convo(F) \subseteq A$. Formulação ideal é aquela tal que $Convo(F) = P_A$

Modelando com variáveis inteiras.

Impor que uma ação x só pode ser feita se outra ação y for realizada.

$$x, y \in [0, 1] | y \leq x$$

Problema da Localização Facilitada:

- Conjunto de facilidades J
- Conjunto de Clientes I

Que facilidades precisam ser abertas para atender as demandas dos Clientes a um custo mínimo?

Seja $C_{i,j}$ o custo da facilidade j atender o cliente i . f_j o custo da abertura de uma facilidade.

Variáveis:

$$X_{j,i} = \begin{cases} 1, & \text{se } j \text{ atende } i \\ 0, & \text{caso contrário.} \end{cases}$$

$$Y_j = \begin{cases} 1, & \text{se } j \text{ aberto} \\ 0, & \text{caso contrário.} \end{cases}$$

Restrições:

$$X_{j,i} \in \{0, 1\}, \forall j \in J, \forall i \in I$$

$$Y_j \in \{0, 1\} \forall j \in J$$

$$\sum_{j \in J} X_{j,i}, \forall i \in I$$

$$|I|Y_j \geq \sum_{i \in I} X_{j,i}$$

Impor que uma variável X assumir apenas um dos valores de um conjunto finito $A = a_1, a_2, \dots, a_m$

$$Y_i = \begin{cases} 1, & \text{se } X \text{ assume } a_i \\ 0, & \text{caso contrário} \end{cases}$$

$$\sum_{i=1}^m Y_i = 1$$

$$X = \sum_{i=1}^m Y_i a_i$$

Modelar funções lineares por partes

- Para cada intervalo que a solução x esteja temos uma função linear diferente
- A função f é conhecida apenas nos pontos a_i
- O valor de f é dado pela combinação linear de dois pontos consecutivos

$$\lambda f(a_i) + (1 - \lambda)f(a_{i+1})$$

Variáveis:

$$Y_i = \begin{cases} 1, & \text{se solução está no intervalo } [a_i, a_{i+1}] \\ 0, & \text{caso contrário, } \forall i = \{1\} \dots k \end{cases}$$

$\lambda_i \rightarrow$ combinação linear, $\forall i = \{1\} \dots k$

Restrições:

$$\min \sum_{i=1}^k \lambda_i = 1$$

$$\min \sum_{i=1}^k Y_i = 1$$

$$\lambda_i \leq Y_i + Y_{i-1} | \forall i = 2, \dots, k$$

$$\lambda_i \leq Y_i$$

$$\lambda_i \geq 0, \text{ for all } i = 1, \dots, k$$

$$Y_i \in \{0, 1\}, \text{ for all } i = 1, \dots, k$$

Objetivo:

$$\min \sum_{i=1}^k \lambda_i f(a_i)$$

Modelando restrições disjuntas

Suponha duas restrições:

- $a^T X \geq b^*$
- $c^T X \geq d^{**}$

Queremos que pelo menos uma delas sejam satisfeitas.

Variáveis:

$$Y = \begin{cases} 1, & \text{se satisfaz } *. \\ 0, & \text{se satisfaz } **. \end{cases}$$

Restrições:

$$a^t X \geq bY$$

$$c^t X \geq d(1 - Y)$$

Suponha que tenho agora k restrições: $a_i^t \geq b_i, \forall i \in [1..k]$, quero ativar p restrições.

minhas restrições extras são:

$$Y_i \in [0, 1], \forall i = 1..k$$

$$\sum_{i=1}^k Y_i = p$$

Exemplo do emparelhamento perfeito

Temos um grupo de n pessoas que precisam formar pares. Seja c_j o custo de parear pessoa i com j .

Queremos minimizar o custo dos emparelhamentos.

Variáveis:

$$x_{i,j} = \begin{cases} 1, & \text{se satisfaz } i \text{ parear com } j. \\ 0, & \text{caso contrário} \end{cases}$$

Restrições:

$$\sum_{j \in E} x_{i,j} = 1$$

Objetivo:

$$\min \sum_{j \in E} x_{i,j} c_{i,j}$$

Exemplo da coloração de vértices

Seja um Grafo G , definimos a coloração de G como a atribuição de uma entre k para cada vértice de forma que dada qqr aresta suas extremidades não compartilham cores.

Variáveis:

$$x_{i,j} = \begin{cases} 1, & \text{se vértice } i \text{ é colorido com } j. \\ 0, & \text{caso contrário} \end{cases}$$

$$w_j = \begin{cases} 1, & \text{se } j \text{ for usado na coloração.} \\ 0, & \text{caso contrário} \end{cases}$$

Restrições:

$$\sum_{j=1}^{|V(G)|} X_{i,j} = 1$$

$$X_{i,j} + x_{k,j} \leq w_j, \forall i, k \in V(G)$$

Objetivo:

$$\min \sum_{j=1}^{|V(G)|} w_j$$

Fortalecer modelo enfraquecendo variáveis

Exemplo: Lot Sizing

Seja $d_t \rightarrow$ demanda do tempo t ; $f_t \rightarrow$ custo de produzir no tempo t ; $p_t \rightarrow$ custo de produção por unidade; $h_t \rightarrow$ custo de armazenamento em t .

Modelagem padrão:

Variáveis:

$X_t \rightarrow$ Qtd produzida em t

$S_t \rightarrow$ Qtd em estoque em t

$$Y_t = \begin{cases} 1, & \text{se algo foi produzido em } t. \\ 0, & \text{caso contrário} \end{cases}$$

Restrições:

$$S_m = 0$$

$$X_t \leq Y_t M$$

$$S_{t-1} + X_t = d_t + S_t$$

removendo M temos

$$X_t \leq Y_t \sum_{t=1}^m d_t$$

Objetivo:

$$\min \sum_{t=1}^m (h_t S_t + f_t Y_t + p_t X_t)$$

Modelagem com fortalecimento

Variáveis:

$W_{i,t} \rightarrow$ Qtd produzida em i para suprir a demanda em t

$S_t \rightarrow$ Qtd em estoque em t

$$Y_t = \begin{cases} 1, & \text{se algo foi produzido em } t. \\ 0, & \text{caso contrário} \end{cases}$$

Restrições:

$$S_m = 0$$

$$S_1 = 0$$

$$W_{i,t} \leq Y_t d_t$$

$$S_{t-1} + \sum_{i=t}^n W_{t,i} = d_t + S_t$$

Objetivo:

$$\min \sum_{t=1}^m (h_t S_t + f_t Y_t + p_t \sum_{i=t}^n W_{t,i})$$

Outra modelagem para coloração

Sabemos que coloração é equivalente a encontrar uma partição de G em k conjuntos idenpendentes maximais.

Dessa forma podemos escolher um vértice como *representante* de seu conjunto independente, nos levando as seguintes variáveis.

Variáveis:

$$X_{i,j} = \begin{cases} 1, & \text{se o vértice } i \text{ e o vértice } j \text{ pertencem ao mesmo conjunto. Onde } i \leq j. \\ 0, & \text{caso contrário} \end{cases}$$

Restrições:

$$\sum_{N(v) \neq u \leq v} X_{u,v} = 1$$

$$X_{k,i} + X_{k,j} \leq X_{k,k}, \forall i, j \in E, \forall k \in V, k \notin N[i] \sup N[j]$$

$$X_{i,j} \leq X_{i,i}$$

Caxeiro viajante

Variáveis

$$X_{i,j} = \begin{cases} 1, & \text{se viajo de } i \text{ para } j. \text{ Onde } i \leq j. \\ 0, & \text{caso contrário} \end{cases}$$

Restrições:

$$\sum_{j \in N(i)} X_{i,j}$$

$$\sum_{j \in N(i)} X_{j,i}$$

$$\sum_{j \in V/S} \sum_{i \in S} X_{j,i} \geq 1$$

$$\sum_{j \in S} \sum_{i \in S} X_{j,i} \leq |S| - 1$$

Seja:

- J um conjunto de n tarefas
- M um conjunto de m máquinas
- Cada tarefa $j \in J$ temos a ordem de processamento $(\lambda_1^j, \lambda_2^j, \dots, \lambda_m^j)$ para a execução de j .

Otimização relaxamento limites

Branch and bound

Plano de corte

Branch and cut

Relaxação Lagrangiana

Geração de colunas em PI

Branch and Price

Teoria Poliédrica

Cortes

Faces

Facetas